CORRIGÉ · PROBLÈME · COMMANDO X-ENS SPÉ

Compter jusqu'à n avec log log n bits

Énoncé

Cadre. On veut compter des événements (des requêtes reçues par un serveur, par exemple) sans stocker le nombre exact n, qui demande $\lfloor \log_2 n \rfloor + 1$ bits. Soit $(u_{i,j})_{i \geqslant 0,\, j \geqslant 1}$ une famille de variables aléatoires **indépendantes**, avec $u_{i,j}$ de loi de Bernoulli de paramètre 2^{-i}. On pose $S_0 = 0$ et, pour $n \geqslant 0$,

$$S_{n+1} = S_n + u_{S_n,\, n+1}.$$

Autrement dit, à la $(n+1)$-ième requête, le compteur passe de S_n à $S_n + 1$ avec probabilité 2^{-S_n}. On pose $Y_n = 2^{S_n} - 1$. Pour $\varepsilon, \delta \in]0,1[$, un (ε, δ)**-estimateur** de $\mu > 0$ est une variable Z telle que $\mathbb{P}(|Z - \mu| \geqslant \varepsilon \mu) \leqslant \delta$.

Partie I. Un estimateur sans biais de n

1. Montrer que $0 \leqslant S_n \leqslant n$, que $S_1 = 1$, et que S_n est une fonction des seules variables $(u_{i,j})_{i \geqslant 0,\, j \leqslant n}$. En déduire que, pour tout k, S_n et $u_{k,n+1}$ sont indépendantes.

2. Calculer $\mathbb{E}\big[2^{u_{k,n+1}}\big]$, puis montrer que $\mathbb{E}\big[2^{S_{n+1}}\big] = \mathbb{E}\big[2^{S_n}\big] + 1$ (on pourra écrire $2^{S_{n+1}} = \sum_{k=0}^{n} 2^{k + u_{k,n+1}} \mathbf{1}_{S_n = k}$).

3. Retrouver ce résultat par une autre méthode : calculer $\mathbb{P}(S_{n+1} = k,\ S_n = k)$ et $\mathbb{P}(S_{n+1} = k,\ S_n = k-1)$, puis $\mathbb{E}\big[2^{S_{n+1}} - 1\big]$ par la formule de transfert.

4. En déduire $\mathbb{E}[Y_n] = n$. Calculer la loi de S_2 et vérifier.

Partie II. Variance et (,)-estimateur

1. Montrer que $\mathbb{E}\big[4^{S_{n+1}}\big] = \mathbb{E}\big[4^{S_n}\big] + 3(n+1)$, puis que $\mathbb{E}\big[4^{S_n}\big] = 1 + \frac{3n(n+1)}{2}$.

2. En déduire $\mathrm{Var}(Y_n) = \dfrac{n(n-1)}{2}$. Vérifier pour $n = 1$ et $n = 2$.

3. Montrer que Y_n seul n'est pas un bon estimateur : majorer $\mathbb{P}(|Y_n - n| \geqslant \varepsilon n)$ par Bienaymé-Tchebychev et commenter.

4. Soient $S_n^{(1)}, \dots, S_n^{(k)}$ des copies indépendantes de S_n (construites avec des familles u indépendantes), $Y_n^{(i)} = 2^{S_n^{(i)}} - 1$ et $U_n = \frac{1}{k} \sum_{i=1}^{k} Y_n^{(i)}$. Montrer que U_n est un (ε, δ)-estimateur de n dès que $k \geqslant \dfrac{1}{2\varepsilon^2 \delta}$.

Partie III. La mémoire utilisée, presque sûrement

On garde les notations de la Partie II, k étant fixé.

1. (**Borel-Cantelli**) Soit (A_n) une suite d'événements telle que $\sum \mathbb{P}(A_n) < +\infty$. Montrer que $\mathbb{P}(\limsup A_n) = 0$.

2. Pour stocker U_n, on stocke les k entiers $S_n^{(i)} \geqslant 1$ ($n \geqslant 1$), ce qui demande $B_n = \sum_{i=1}^{k} (\lfloor \log_2 S_n^{(i)} \rfloor + 1)$ bits. On note $L_n = \log_2 \log_2 n$. Montrer que, pour $n \geqslant 4$,

$$\{B_n \geqslant 3kL_n\} \subset \bigcup_{i=1}^{k} \left\{ Y_n^{(i)} - n \geqslant n^{\log_2 n} - n - 1 \right\}.$$

3. En déduire que $\mathbb{P}(B_n \geqslant 3kL_n) \leqslant \dfrac{2k}{n^6}$ pour $n \geqslant 16$.

4. Conclure que, presque sûrement, $B_n < 3k \log_2 \log_2 n$ pour tout n assez grand. Comparer avec le stockage exact de n.

Décoder l'énoncé

Ce que l'énoncé te donne.

- $u_{k,n+1} \sim \mathcal{B}(2^{-k})$, indépendante de S_n.
- $\mathbb{E}[2^{S_n}] = n + 1$ (Partie I).
- $\mathrm{Var}(Y_n) = \frac{n(n-1)}{2}$.

Ce qu'on te demande. On étudie un compteur probabiliste : au lieu de stocker n, on stocke un entier S_n de l'ordre de $\log_2$ n, incrémenté avec une probabilité qui décroît. On montre que 2^{S_n} − 1 estime n sans biais, on calcule sa variance, on construit un (,)-estimateur par moyenne de copies indépendantes, et on contrôle la mémoire presque sûrement avec le lemme de Borel-Cantelli.

Corrigé

Question 1

Chaque pas ajoute $u_{S_n,n+1} \in \{0,1\}$, donc par récurrence $0 \leqslant S_n \leqslant n$. $u_{0,1}$ suit la loi $\mathcal{B}(2^0) = \mathcal{B}(1)$: elle vaut 1 presque sûrement, et $S_1 = 0 + u_{0,1} = 1$.

Par récurrence, S_n est une fonction des $u_{i,j}$ pour $j \leqslant n$: c'est vrai pour $S_0 = 0$, et $S_{n+1} = S_n + \sum_{i=0}^{n} \mathbf{1}_{S_n=i} u_{i,n+1}$ ne fait intervenir que S_n et les $u_{i,n+1}$.

Les familles $(u_{i,j})_{j \leqslant n}$ et $\{u_{k,n+1}\}$ sont disjointes, donc (lemme des coalitions) S_n et $u_{k,n+1}$ sont indépendantes.

Question 2

Pour $u \sim \mathcal{B}(2^{-k})$: 2^u vaut 2 avec probabilité 2^{-k} et 1 sinon, donc

$$\mathbb{E}[2^{u_{k,n+1}}] = 2 \cdot 2^{-k} + (1 - 2^{-k}) = 1 + 2^{-k}.$$

Sur $\{S_n = k\}$, $S_{n+1} = k + u_{k,n+1}$; comme $0 \leqslant S_n \leqslant n$, la somme est finie :

$$2^{S_{n+1}} = \sum_{k=0}^{n} 2^k \cdot 2^{u_{k,n+1}} \mathbf{1}_{S_n = k}.$$

Par linéarité et indépendance de $u_{k,n+1}$ et $\mathbf{1}_{S_n=k}$ (Q1) :

$$\begin{aligned}\mathbb{E}[2^{S_{n+1}}] &= \sum_{k=0}^{n} 2^k (1 + 2^{-k})\, \mathbb{P}(S_n = k) \\ &= \sum_{k=0}^{n} 2^k\, \mathbb{P}(S_n = k) + \sum_{k=0}^{n} \mathbb{P}(S_n = k).\end{aligned}$$

$$\boxed{\mathbb{E}[2^{S_{n+1}}] = \mathbb{E}[2^{S_n}] + 1.}$$

Question 3

Par indépendance :

$$\mathbb{P}(S_{n+1} = k,\ S_n = k) = \mathbb{P}(S_n = k,\ u_{k,n+1} = 0) = \mathbb{P}(S_n = k)(1 - 2^{-k}),$$

$$\mathbb{P}(S_{n+1} = k,\ S_n = k-1) = \mathbb{P}(S_n = k-1)\, 2^{-(k-1)}.$$

Comme $S_{n+1} = k$ impose $S_n \in \{k, k-1\}$, la formule de transfert donne (le terme $k = 0$ est nul) :

$$\mathbb{E}[2^{S_{n+1}} - 1] = \sum_{k \geqslant 1} (2^k - 1) \Big[\mathbb{P}(S_n = k)(1 - 2^{-k}) + \mathbb{P}(S_n = k-1)\, 2^{-k+1} \Big].$$

On décale l'indice dans la seconde somme ($k \to k+1$) et on regroupe selon $\mathbb{P}(S_n = k)$, $k \geqslant 0$:

$$\begin{aligned}\mathbb{E}[2^{S_{n+1}} - 1] &= \sum_{k \geqslant 0} \Big[(2^k - 1)(1 - 2^{-k}) + (2^{k+1} - 1) 2^{-k} \Big] \mathbb{P}(S_n = k) \\ &= \sum_{k \geqslant 0} \Big[2^k - 1 - 1 + 2^{-k} + 2 - 2^{-k} \Big] \mathbb{P}(S_n = k) \\ &= \sum_{k \geqslant 0} 2^k\, \mathbb{P}(S_n = k).\end{aligned}$$

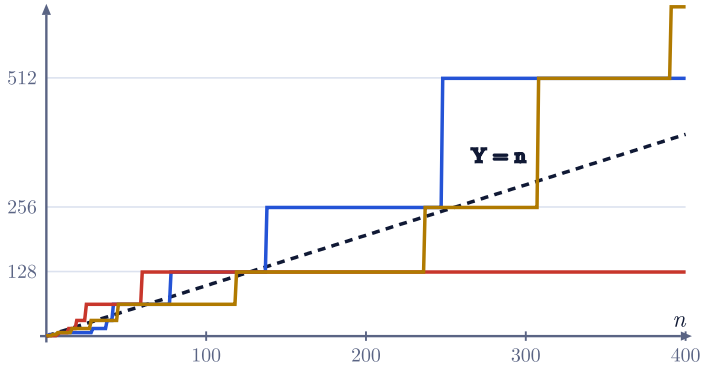
C'est $\mathbb{E}[2^{S_n}]$: on retrouve $\mathbb{E}[2^{S_{n+1}}] = \mathbb{E}[2^{S_n}] + 1$.

Question 4

Par récurrence, $\mathbb{E}[2^{S_n}] = \mathbb{E}[2^{S_0}] + n = n+1$, donc

$$\mathbb{E}[Y_n] = \mathbb{E}[2^{S_n}] - 1 = n.$$

Vérification pour $n = 2$. $S_1 = 1$, puis $S_2 = 1 + u_{1,2}$ avec $u_{1,2} \sim \mathcal{B}(\frac{1}{2})$: $S_2 \in \{1, 2\}$ avec probabilité $\frac{1}{2}$ chacun. Alors $Y_2 \in \{1, 3\}$ et $\mathbb{E}[Y_2] = \frac{1}{2}(1+3) = 2$.



Trois trajectoires simulées de $Y_n = 2^{S_n} - 1$ pour $n \leqslant 400$. Le compteur ne prend que les valeurs $2^s - 1$; il reste en moyenne sur la droite $Y = n$, et chaque trajectoire ne stocke que $S_n \leqslant 9$.

Question 5

Même découpage qu'en Q2, avec $\mathbb{E}[4^{u_{k,n+1}}] = 4 \cdot 2^{-k} + (1 - 2^{-k}) = 1 + 3 \cdot 2^{-k}$:

$$\begin{aligned}\mathbb{E}[4^{S_{n+1}}] &= \sum_{k=0}^{n} 4^k (1 + 3 \cdot 2^{-k})\, \mathbb{P}(S_n = k) \\ &= \sum_{k=0}^{n} (4^k + 3 \cdot 2^k) \mathbb{P}(S_n = k) = \mathbb{E}[4^{S_n}] + 3\,\mathbb{E}[2^{S_n}].\end{aligned}$$

Avec $\mathbb{E}[2^{S_n}] = n + 1$: $\mathbb{E}[4^{S_{n+1}}] = \mathbb{E}[4^{S_n}] + 3(n+1)$. En sommant à partir de $\mathbb{E}[4^{S_0}] = 1$:

$$\mathbb{E}[4^{S_n}] = 1 + 3\sum_{j=0}^{n-1}(j+1) = 1 + \frac{3n(n+1)}{2}.$$

Question 6

Une translation ne change pas la variance, et $(2^{S_n})^2 = 4^{S_n}$:

$$\begin{aligned}\mathrm{Var}(Y_n) &= \mathbb{E}[4^{S_n}] - \mathbb{E}[2^{S_n}]^2 = 1 + \frac{3n(n+1)}{2} - (n+1)^2 \\ &= \frac{2 + 3n^2 + 3n - 2n^2 - 4n - 2}{2}.\end{aligned}$$

$$\mathrm{Var}(Y_n) = \frac{n^2 - n}{2} = \frac{n(n-1)}{2}.$$

Vérifications. $n = 1$: $Y_1 = 1$ est constante, variance 0. $n = 2$: $Y_2 \in \{1, 3\}$ équiprobables, variance $\frac{1}{2}(1-2)^2 + \frac{1}{2}(3-2)^2 = 1 = \frac{2 \cdot 1}{2}$.

Question 7

Bienaymé-Tchebychev :

$$\mathbb{P}(|Y_n - n| \geqslant \varepsilon n) \leqslant \frac{n(n-1)}{2\varepsilon^2 n^2} \leqslant \frac{1}{2\varepsilon^2}.$$

Pour $\varepsilon < \frac{1}{\sqrt{2}}$, cette borne dépasse 1 : elle ne dit rien. L'écart-type de Y_n est de l'ordre de $\frac{n}{\sqrt{2}}$, comparable à n : un seul compteur a une erreur relative de l'ordre de 70 %.

Question 8

Par linéarité, $\mathbb{E}[U_n] = n$. Par indépendance des copies :

$$\mathrm{Var}(U_n) = \frac{1}{k^2} \sum_{i=1}^{k} \mathrm{Var}(Y_n^{(i)}) = \frac{n(n-1)}{2k}.$$

Bienaymé-Tchebychev :

$$\mathbb{P}(|U_n - n| \geqslant \varepsilon n) \leqslant \frac{n(n-1)}{2k\varepsilon^2 n^2} \leqslant \frac{1}{2k\varepsilon^2} \leqslant \delta \quad \text{dès que} \quad k \geqslant \frac{1}{2\varepsilon^2 \delta}.$$

Avec $k = \left\lceil \frac{1}{2\varepsilon^2 \delta} \right\rceil$ copies, U_n est un (ε, δ)-estimateur de n, pour **tout** n.

Exemple : $\varepsilon = 0{,}1$, $\delta = 0{,}05$ donne $k = 1000$.

Question 9

Pour tout n, $\limsup A_k \subset \bigcup_{k \geqslant n} A_k$, donc par sous-additivité

$$\mathbb{P}(\limsup A_k) \leqslant \sum_{k \geqslant n} \mathbb{P}(A_k).$$

Le membre de droite est le reste d'une série convergente : il tend vers 0 quand $n \to +\infty$. Donc $\mathbb{P}(\limsup A_n) = 0$.

Presque sûrement, seul un nombre fini des A_n est réalisé.

Question 10

Si $B_n \geqslant 3kL_n$, l'un des k termes vaut au moins $3L_n$: il existe i avec $\lfloor \log_2 S_n^{(i)} \rfloor + 1 \geqslant 3L_n$, donc $\log_2 S_n^{(i)} \geqslant 3L_n - 1$.

Pour $n \geqslant 4$, $\log_2 n \geqslant 2$ et $L_n \geqslant 1$, donc $3L_n - 1 \geqslant 2L_n$ et $S_n^{(i)} \geqslant 2^{2L_n} = (\log_2 n)^2$. Alors

$$2^{S_n^{(i)}} \geqslant 2^{(\log_2 n)^2} = \left(2^{\log_2 n}\right)^{\log_2 n} = n^{\log_2 n},$$

soit $Y_n^{(i)} - n \geqslant n^{\log_2 n} - 1 - n$.

Question 11

Pour $n \geqslant 16$, $\log_2 n \geqslant 4$ et $\alpha_n = n^{\log_2 n} - n - 1 \geqslant n^4 - n - 1 \geqslant \frac{n^4}{2}$ (car $\frac{n^4}{2} \geqslant n + 1$). Par la question 10, la sous-additivité, puis Bienaymé-Tchebychev (les $Y_n^{(i)}$ ont la loi de Y_n) :

$$\mathbb{P}(B_n \geqslant 3kL_n) \leqslant k\,\mathbb{P}(|Y_n - n| \geqslant \alpha_n) \leqslant k\frac{n(n-1)}{2\alpha_n^2} \leqslant k\frac{n^2}{2} \cdot \frac{4}{n^8} = \frac{2k}{n^6}.$$

Question 12

$\sum_n \frac{2k}{n^6} < +\infty$, donc par Borel-Cantelli, presque sûrement l'événement $\{B_n \geqslant 3kL_n\}$ n'est réalisé que pour un nombre fini de n :

> Presque sûrement, à partir d'un certain rang, $B_n < 3k \log_2 \log_2 n$.

Le stockage exact de n demande $\lfloor \log_2 n \rfloor + 1$ bits. Pour $n = 10^9$: environ 30 bits pour le compteur exact, contre $3 \log_2(30) \approx 15$ bits par copie. Le gain devient très net quand on surveille des millions de compteurs (un par adresse IP, par exemple) : on paie la précision ε et le risque δ par le facteur k.

Le piège

Partie I. Écrire $\mathbb{E}[2^{S_{n+1}}] = \mathbb{E}[2^{S_n}]\,\mathbb{E}[2^{u_{S_n,n+1}}]$: l'indice S_n est aléatoire, et $u_{S_n,n+1}$ n'est pas indépendante de S_n. Il faut découper selon les valeurs de S_n.
Partie II. Le choix de k ne doit pas dépendre de n : c'est le cas ici car $\frac{n(n-1)}{n^2} \leqslant 1$. Si la variance avait été d'ordre n^3, aucune taille fixe ne conviendrait.
Partie III. Borel-Cantelli ne dit pas que $B_n < 3kL_n$ pour tout n : pour un nombre fini de n (aléatoire), la borne peut être dépassée. « Presque sûrement à partir d'un certain rang » est exactement ce que donne le lemme.

La méthode

Partie I. Variable indexée par une variable aléatoire : découper sur $\{S_n = k\}$, où l'indice devient fixe, puis utiliser l'indépendance terme à terme.
Partie II. Réduire la variance en moyennant k copies indépendantes : l'écart-type est divisé par $\sqrt{k}$, et Bienaymé-Tchebychev donne une taille d'échantillon explicite.
Partie III. Pour un résultat presque sûr « à partir d'un certain rang » : majorer $\mathbb{P}(A_n)$ par le terme d'une série convergente (ici par Bienaymé-Tchebychev), puis appliquer Borel-Cantelli.

Rappels de cours utilisés

- **Indépendance et espérance.**

$$X \perp\!\!\!\perp Y \implies \mathbb{E}[XY] = \mathbb{E}[X]\,\mathbb{E}[Y].$$

$$I \cap J = \emptyset \implies f((X_i)_{i\in I}) \perp\!\!\!\perp g((X_j)_{j\in J}).$$

- **Bienaymé-Tchebychev.**

$$\forall \alpha > 0, \quad \mathbb{P}(|X - \mathbb{E}[X]| \geqslant \alpha) \leqslant \frac{\mathrm{Var}(X)}{\alpha^2},$$

$$X_i \text{ indépendantes} \Rightarrow \mathrm{Var}\left(\sum X_i\right) = \sum \mathrm{Var}(X_i).$$

- **Limite supérieure d'événements.**

$$\limsup A_n = \bigcap_{n\geqslant 0}\bigcup_{k\geqslant n} A_k \text{ (une infinité des } A_k), \qquad \overline{\limsup A_n} = \bigcup_{n}\bigcap_{k\geqslant n} \overline{A_k}.$$