CORRIGÉ · PROBLÈME · COMMANDO X-ENS SPÉ

Variance et (ε, δ)-estimateur

Énoncé

Cadre. On veut compter des événements (des requêtes reçues par un serveur, par exemple) sans stocker le nombre exact n, qui demande $\lfloor \log_2 n \rfloor + 1$ bits. Soit $(u_{i,j})_{i \geqslant 0,\, j \geqslant 1}$ une famille de variables aléatoires **indépendantes**, avec $u_{i,j}$ de loi de Bernoulli de paramètre 2^{-i}. On pose $S_0 = 0$ et, pour $n \geqslant 0$,

$$S_{n+1} = S_n + u_{S_n,\, n+1}.$$

Autrement dit, à la $(n+1)$-ième requête, le compteur passe de S_n à $S_n + 1$ avec probabilité 2^{-S_n}. On pose $Y_n = 2^{S_n} - 1$. Pour $\varepsilon, \delta \in]0,1[$, un (ε, δ)**-estimateur** de $\mu > 0$ est une variable Z telle que $\mathbb{P}(|Z - \mu| \geqslant \varepsilon \mu) \leqslant \delta$.

Partie II.

1. Montrer que $\mathbb{E}[4^{S_{n+1}}] = \mathbb{E}[4^{S_n}] + 3(n+1)$, puis que $\mathbb{E}[4^{S_n}] = 1 + \frac{3n(n+1)}{2}$.
2. En déduire $\mathrm{Var}(Y_n) = \dfrac{n(n-1)}{2}$. Vérifier pour $n = 1$ et $n = 2$.
3. Montrer que Y_n seul n'est pas un bon estimateur : majorer $\mathbb{P}(|Y_n - n| \geqslant \varepsilon n)$ par Bienaymé-Tchebychev et commenter.
4. Soient $S_n^{(1)}, \dots, S_n^{(k)}$ des copies indépendantes de S_n (construites avec des familles u indépendantes), $Y_n^{(i)} = 2^{S_n^{(i)}} - 1$ et $U_n = \frac{1}{k} \sum_{i=1}^{k} Y_n^{(i)}$. Montrer que U_n est un (ε, δ)-estimateur de n dès que $k \geqslant \dfrac{1}{2\varepsilon^2 \delta}$.

Décoder l'énoncé

Ce que l'énoncé te donne.

- $\mathbb{E}[2^{S_n}] = n + 1$ (Partie I).

Ce qu'on te demande. Calculer le moment d'ordre 2 de 2^{S_n}, puis moyenner pour réduire la variance.

Corrigé

Question 5

Étape 1. Le moment d'ordre 2

Même découpage qu'en Q2, avec $\mathbb{E}[4^{u_{k,n+1}}] = 4\cdot 2^{-k} + (1-2^{-k}) = 1 + 3\cdot 2^{-k}$:

$$\begin{aligned}\mathbb{E}[4^{S_{n+1}}] &= \sum_{k=0}^{n} 4^k(1+3\cdot 2^{-k})\,\mathbb{P}(S_n = k)\\ &= \sum_{k=0}^{n}(4^k + 3\cdot 2^k)\mathbb{P}(S_n=k) = \mathbb{E}[4^{S_n}] + 3\,\mathbb{E}[2^{S_n}].\end{aligned}$$

Avec $\mathbb{E}[2^{S_n}] = n+1$: $\mathbb{E}[4^{S_{n+1}}] = \mathbb{E}[4^{S_n}] + 3(n+1)$. En sommant à partir de $\mathbb{E}[4^{S_0}] = 1$:

$$\mathbb{E}[4^{S_n}] = 1 + 3\sum_{j=0}^{n-1}(j+1) = 1 + \frac{3n(n+1)}{2}.$$

Question 6

Étape 1. La variance

Une translation ne change pas la variance, et $(2^{S_n})^2 = 4^{S_n}$:

$$\begin{aligned}\mathrm{Var}(Y_n) &= \mathbb{E}[4^{S_n}] - \mathbb{E}[2^{S_n}]^2 = 1 + \frac{3n(n+1)}{2} - (n+1)^2\\ &= \frac{2 + 3n^2 + 3n - 2n^2 - 4n - 2}{2}.\end{aligned}$$

$$\mathrm{Var}(Y_n) = \frac{n^2-n}{2} = \frac{n(n-1)}{2}.$$

Vérifications. $n=1$: $Y_1 = 1$ est constante, variance 0. $n=2$: $Y_2 \in \{1,3\}$ équiprobables, variance $\frac{1}{2}(1-2)^2 + \frac{1}{2}(3-2)^2 = 1 = \frac{2\cdot 1}{2}$.

Question 7

Étape 1. Un seul compteur ne suffit pas

Bienaymé-Tchebychev :

$$\mathbb{P}(|Y_n - n| \geqslant \varepsilon n) \leqslant \frac{n(n-1)}{2\varepsilon^2 n^2} \leqslant \frac{1}{2\varepsilon^2}.$$

Pour $\varepsilon < \frac{1}{\sqrt{2}}$, cette borne dépasse 1 : elle ne dit rien. L'écart-type de Y_n est de l'ordre de $\frac{n}{\sqrt{2}}$, comparable à n : un seul compteur a une erreur relative de l'ordre de 70 %.

Question 8

Étape 1. Moyenne de k copies

Par linéarité, $\mathbb{E}[U_n] = n$. Par indépendance des copies :

$$\mathrm{Var}(U_n) = \frac{1}{k^2}\sum_{i=1}^{k}\mathrm{Var}(Y_n^{(i)}) = \frac{n(n-1)}{2k}.$$

Bienaymé-Tchebychev :

$$\mathbb{P}(|U_n - n| \geqslant \varepsilon n) \leqslant \frac{n(n-1)}{2k\varepsilon^2 n^2} \leqslant \frac{1}{2k\varepsilon^2} \leqslant \delta \quad \text{dès que} \quad k \geqslant \frac{1}{2\varepsilon^2\delta}.$$

Avec $k = \left\lceil \frac{1}{2\varepsilon^2\delta} \right\rceil$ copies, U_n est un (ε, δ)-estimateur de n, pour **tout** n.

Exemple : $\varepsilon = 0{,}1$, $\delta = 0{,}05$ donne $k = 1000$.

Le piège

Le choix de k ne doit pas dépendre de n : c'est le cas ici car $\frac{n(n-1)}{n^2} \leqslant 1$. Si la variance avait été d'ordre n^3, aucune taille fixe ne conviendrait.

La méthode

Réduire la variance en moyennant k copies indépendantes : l'écart-type est divisé par $\sqrt{k}$, et Bienaymé-Tchebychev donne une taille d'échantillon explicite.

Rappels de cours utilisés

- **Indépendance et espérance.** Si X et Y sont indépendantes et intégrables, $\mathbb{E}[XY] = \mathbb{E}[X]\,\mathbb{E}[Y]$. Des fonctions de familles disjointes de variables indépendantes sont indépendantes (lemme des coalitions).
- **Bienaymé-Tchebychev.** Si X admet une variance : $\mathbb{P}(|X - \mathbb{E}[X]| \geqslant \alpha) \leqslant \dfrac{\mathrm{Var}(X)}{\alpha^2}$ pour tout $\alpha > 0$. Pour $X_1, \dots, X_k$ indépendantes, $\mathrm{Var}(X_1 + \cdots + X_k) = \sum \mathrm{Var}(X_i)$.