CORRIGÉ · PROBLÈME · COMMANDO X-ENS SPÉ

La mémoire utilisée, presque sûrement

Énoncé

Cadre. On veut compter des événements (des requêtes reçues par un serveur, par exemple) sans stocker le nombre exact n, qui demande $\lfloor \log_2 n \rfloor + 1$ bits. Soit $(u_{i,j})_{i \geqslant 0,\, j \geqslant 1}$ une famille de variables aléatoires **indépendantes**, avec $u_{i,j}$ de loi de Bernoulli de paramètre 2^{-i}. On pose $S_0 = 0$ et, pour $n \geqslant 0$,

$$S_{n+1} = S_n + u_{S_n,\, n+1}.$$

Autrement dit, à la $(n+1)$-ième requête, le compteur passe de S_n à $S_n + 1$ avec probabilité 2^{-S_n}. On pose $Y_n = 2^{S_n} - 1$. Pour $\varepsilon, \delta \in]0,1[$, un (ε, δ)**-estimateur** de $\mu > 0$ est une variable Z telle que $\mathbb{P}(|Z - \mu| \geqslant \varepsilon\mu) \leqslant \delta$.

Partie III. On garde les notations de la Partie II, k étant fixé.

1. (**Borel-Cantelli**) Soit (A_n) une suite d'événements telle que $\sum \mathbb{P}(A_n) < +\infty$. Montrer que $\mathbb{P}(\limsup A_n) = 0$.

2. Pour stocker U_n, on stocke les k entiers $S_n^{(i)} \geqslant 1$ $(n \geqslant 1)$, ce qui demande $B_n = \sum_{i=1}^{k} (\lfloor \log_2 S_n^{(i)} \rfloor + 1)$ bits. On note $L_n = \log_2 \log_2 n$. Montrer que, pour $n \geqslant 4$,

$$\{B_n \geqslant 3kL_n\} \subset \bigcup_{i=1}^{k} \left\{ Y_n^{(i)} - n \geqslant n^{\log_2 n} - n - 1 \right\}.$$

3. En déduire que $\mathbb{P}(B_n \geqslant 3kL_n) \leqslant \dfrac{2k}{n^6}$ pour $n \geqslant 16$.

4. Conclure que, presque sûrement, $B_n < 3k \log_2 \log_2 n$ pour tout n assez grand. Comparer avec le stockage exact de n.

Décoder l'énoncé

Ce que l'énoncé te donne.

- $\mathrm{Var}(Y_n) = \frac{n(n-1)}{2}$.

Ce qu'on te demande. Rendre la probabilité de dépasser la mémoire prévue sommable, puis appliquer Borel-Cantelli.

Corrigé

Question 9

Étape 1. Lemme de Borel-Cantelli

Pour tout n, $\limsup A_k \subset \bigcup_{k\geqslant n} A_k$, donc par sous-additivité

$$\mathbb{P}(\limsup A_k) \leqslant \sum_{k\geqslant n} \mathbb{P}(A_k).$$

Le membre de droite est le reste d'une série convergente : il tend vers 0 quand $n \to +\infty$. Donc $\mathbb{P}(\limsup A_n) = 0$.

> Presque sûrement, seul un nombre fini des A_n est réalisé.

Question 10

Étape 1. Traduire la mémoire en valeur de Y_n

Si $B_n \geqslant 3kL_n$, l'un des k termes vaut au moins $3L_n$: il existe i avec $\lfloor \log_2 S_n^{(i)} \rfloor + 1 \geqslant 3L_n$, donc $\log_2 S_n^{(i)} \geqslant 3L_n - 1$.

Pour $n \geqslant 4$, $\log_2 n \geqslant 2$ et $L_n \geqslant 1$, donc $3L_n - 1 \geqslant 2L_n$ et $S_n^{(i)} \geqslant 2^{2L_n} = (\log_2 n)^2$. Alors

$$2^{S_n^{(i)}} \geqslant 2^{(\log_2 n)^2} = \left(2^{\log_2 n}\right)^{\log_2 n} = n^{\log_2 n},$$

soit $Y_n^{(i)} - n \geqslant n^{\log_2 n} - 1 - n$.

Question 11

Étape 1. Une probabilité sommable

Pour $n \geqslant 16$, $\log_2 n \geqslant 4$ et $\alpha_n = n^{\log_2 n} - n - 1 \geqslant n^4 - n - 1 \geqslant \frac{n^4}{2}$ (car $\frac{n^4}{2} \geqslant n + 1$). Par la question 10, la sous-additivité, puis Bienaymé-Tchebychev (les $Y_n^{(i)}$ ont la loi de Y_n) :

$$\mathbb{P}(B_n \geqslant 3kL_n) \leqslant k\,\mathbb{P}(|Y_n - n| \geqslant \alpha_n) \leqslant k\frac{n(n-1)}{2\alpha_n^2} \leqslant k\frac{n^2}{2} \cdot \frac{4}{n^8} = \frac{2k}{n^6}.$$

Question 12

Étape 1. Conclusion

$\sum_n \frac{2k}{n^6} < +\infty$, donc par Borel-Cantelli, presque sûrement l'événement $\{B_n \geqslant 3kL_n\}$ n'est réalisé que pour un nombre fini de n :

> Presque sûrement, à partir d'un certain rang, $B_n < 3k \log_2 \log_2 n$.

Le stockage exact de n demande $\lfloor \log_2 n \rfloor + 1$ bits. Pour $n = 10^9$: environ 30 bits pour le compteur exact, contre $3 \log_2(30) \approx 15$ bits par copie. Le gain devient très net quand on surveille des millions de compteurs (un par adresse IP, par exemple) : on paie la précision ε et le risque δ par le facteur k.

Le piège

Borel-Cantelli ne dit pas que $B_n < 3kL_n$ pour tout n : pour un nombre fini de n (aléatoire), la borne peut être dépassée. « Presque sûrement à partir d'un certain rang » est exactement ce que donne le lemme.

La méthode

Pour un résultat presque sûr « à partir d'un certain rang » : majorer $\mathbb{P}(A_n)$ par le terme d'une série convergente (ici par Bienaymé-Tchebychev), puis appliquer Borel-Cantelli.

Rappels de cours utilisés

- **Limite supérieure d'événements.** $\limsup A_n = \bigcap_{n \geqslant 0} \bigcup_{k \geqslant n} A_k$ est l'événement « une infinité des A_k sont réalisés ». Son complémentaire est « à partir d'un certain rang, aucun A_k n'est réalisé ».
- **Bienaymé-Tchebychev.** Si X admet une variance : $\mathbb{P}(|X - \mathbb{E}[X]| \geqslant \alpha) \leqslant \dfrac{\mathrm{Var}(X)}{\alpha^2}$ pour tout $\alpha > 0$. Pour $X_1, \dots, X_k$ indépendantes, $\mathrm{Var}(X_1 + \cdots + X_k) = \sum \mathrm{Var}(X_i)$.