CORRIGÉ · PROBLÈME · COMMANDO X-ENS SPÉ

Méthodes itératives pour les systèmes linéaires

Énoncé

Cadre. $A \in GL_n(\mathbb{R})$, $b \in \mathbb{R}^n$, et $x^* = A^{-1}b$. On écrit $A = M - N$ avec $M \in GL_n(\mathbb{R})$ « facile à inverser », et on définit, pour $x_0 \in \mathbb{R}^n$, $x_{k+1} = M^{-1}(Nx_k + b)$. On note $\rho(B)$ le rayon spectral (plus grand module des valeurs propres complexes). On écrit aussi $A = L + D + U$ (parties strictement inférieure, diagonale, strictement supérieure).

Partie I. Le lemme de Householder

1. Montrer que la norme subordonnée à $\|\cdot\|_\infty$ sur $\mathbb{C}^n$ est $|||B|||_\infty = \max_i \sum_j |B_{i,j}|$.
2. Soit T triangulaire supérieure et $D_\delta = \mathrm{diag}(1, \delta, \dots, \delta^{n-1})$, $\delta > 0$. Calculer $D_\delta^{-1} T D_\delta$.
3. (**Householder**) Soient $B \in \mathcal{M}_n(\mathbb{C})$ et $\varepsilon > 0$. Montrer qu'il existe une norme sur $\mathbb{C}^n$ dont la norme subordonnée vérifie $|||B||| < \rho(B) + \varepsilon$.
4. En déduire : $B^k \to 0 \iff \rho(B) < 1$, puis $|||B^k|||^{1/k} \to \rho(B)$ pour toute norme subordonnée.

Partie II. Critère de convergence

On pose $e_k = x_k - x^*$ et $B = M^{-1}N$.

1. Montrer que $e_{k+1} = Be_k$, donc $e_k = B^k e_0$.
2. Montrer que si $\rho(B) < 1$, alors $x_k \to x^*$ pour tout $x_0 \in \mathbb{R}^n$.
3. Montrer que si $\rho(B) \geqslant 1$, il existe $x_0 \in \mathbb{R}^n$ tel que (x_k) ne converge pas vers x^*. (Attention : x_0 doit être réel.)
4. Montrer que $\sup_{\|e_0\|_\infty = 1} \|e_k\|_\infty^{1/k} \to \rho(B)$: $\rho(B)$ mesure la vitesse de convergence.

Partie III. Jacobi, Gauss-Seidel, relaxation

Jacobi : $M = D$, $N = -(L + U)$. **Gauss-Seidel** : $M = D + L$, $N = -U$. **Relaxation** ($\omega > 0$) : $M = \frac{1}{\omega} D + L$, $N = (\frac{1}{\omega} - 1)D - U$ (pour $\omega = 1$, c'est Gauss-Seidel).

1. Montrer que Jacobi converge si A est à diagonale strictement dominante : $|a_{i,i}| > \sum_{j \neq i} |a_{i,j}|$ pour tout i. Montrer qu'une dominance large ($\geqslant$) ne suffit pas, avec $A = \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix}$.

2. Soit $A = \begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix}$. Calculer ρ_J (Jacobi) et ρ_{GS} (Gauss-Seidel), et vérifier $\rho_{GS} = \rho_J^2$.

3. Montrer que $|\det(M^{-1}N)| = |1-\omega|^n$ pour la relaxation. En déduire que la relaxation ne peut converger pour tout x_0 que si $\omega \in]0,2[$.

4. Pour une matrice symétrique définie positive tridiagonale, on admet que le paramètre optimal est $\omega_0 = \frac{2}{1+\sqrt{1-\rho_J^2}}$, avec $\rho(L_{\omega_0}) = \omega_0 - 1$. Le calculer pour la matrice de Q10, et comparer les nombres d'itérations pour gagner un facteur 10^6.

Décoder l'énoncé

Ce que l'énoncé te donne.

- Trigonalisation, normes subordonnées.
- Partie I.
- Partie II.

Ce qu'on te demande. Pour résoudre Ax = b, on écrit A = M − N et on itère x_{k+1} = M⁻¹(Nx_k + b). La méthode converge pour tout point de départ si et seulement si (M⁻¹N) < 1 ; la clé est le lemme de Householder (une norme subordonnée presque égale au rayon spectral). Comparaison de Jacobi, Gauss-Seidel et de la relaxation sur le laplacien discret.

Corrigé

Question 1

Pour $\|x\|_\infty \leqslant 1$: $|(Bx)_i| = \left|\sum_j B_{i,j}x_j\right| \leqslant \sum_j |B_{i,j}|$, donc $|||B|||_\infty \leqslant \max_i \sum_j |B_{i,j}| = \sum_j |B_{i_0,j}|$.

Réciproquement, $x_j = \frac{\overline{B_{i_0,j}}}{|B_{i_0,j}|}$ (et $x_j = 1$ si $B_{i_0,j} = 0$) donne $\|x\|_\infty = 1$ et $(Bx)_{i_0} = \sum_j |B_{i_0,j}|$. D'où l'égalité.

Question 2

Avec $d_i = \delta^{i-1}$, $(D_\delta^{-1} T D_\delta)_{i,j} = \delta^{-(i-1)} T_{i,j} \delta^{j-1} = \delta^{j-i} T_{i,j}$:

$$D_\delta^{-1} T D_\delta = \begin{pmatrix} T_{1,1} & \delta T_{1,2} & \cdots & \delta^{n-1} T_{1,n} \\ & T_{2,2} & \ddots & \vdots \\ & & \ddots & \delta T_{n-1,n} \\ 0 & & & T_{n,n} \end{pmatrix}.$$

La diagonale est inchangée, les termes au-dessus sont multipliés par des puissances positives de δ. (Le livre écrit δ^{n+1} pour le dernier coefficient de D_δ : c'est δ^{n-1}.)

Question 3

Trigonalisons : $B = PTP^{-1}$. Posons $Q = PD_\delta$ et $\|x\| = \|Q^{-1}x\|_\infty$ (norme, car Q inversible). Avec $x = Qy$:

$$|||B||| = \sup_{\|Q^{-1}x\|_\infty \leqslant 1} \|Q^{-1}Bx\|_\infty = \sup_{\|y\|_\infty \leqslant 1} \|Q^{-1}BQy\|_\infty = |||D_\delta^{-1}TD_\delta|||_\infty.$$

Par Q1 et Q2, $|||B||| = \max_i \left(|T_{i,i}| + \sum_{j>i} \delta^{j-i}|T_{i,j}|\right)$. On choisit $\delta \in]0,1]$ tel que $\sum_{j>i} \delta^{j-i}|T_{i,j}| \leqslant \delta \sum_{j>i} |T_{i,j}| < \varepsilon$ pour tout i. Comme $\max_i |T_{i,i}| = \rho(B)$:

$$|||B||| < \rho(B) + \varepsilon.$$

Question 4

Si $B^k \to 0$ et $Bv = \lambda v$ ($v \neq 0$), alors $\lambda^k v = B^k v \to 0$, donc $|\lambda| < 1$: $\rho(B) < 1$. Si $\rho(B) < 1$, Q3 avec $\varepsilon = \frac{1-\rho(B)}{2}$ donne $|||B||| < 1$, puis $|||B^k||| \leqslant |||B|||^k \to 0$.

Pour toute norme subordonnée N : $\rho(B)^k = \rho(B^k) \leqslant N(B^k)$, donc $\rho(B) \leqslant N(B^k)^{1/k}$. Pour $\varepsilon > 0$, la norme $|||\cdot|||$ de Q3 est équivalente à N : $N \leqslant C|||\cdot|||$, d'où $N(B^k)^{1/k} \leqslant C^{1/k}(\rho(B)+\varepsilon) \to \rho(B)+\varepsilon$. Ainsi $N(B^k)^{1/k} \to \rho(B)$ (formule de Gelfand).

Question 5

$Ax^* = b$ s'écrit $Mx^* = Nx^* + b$, soit $x^* = M^{-1}(Nx^* + b)$. En soustrayant : $e_{k+1} = M^{-1}(Nx_k + b) - M^{-1}(Nx^* + b) = M^{-1}Ne_k = Be_k$, et par récurrence $e_k = B^k e_0$.

Question 6

Si $\rho(B) < 1$, $B^k \to 0$ (Q4), donc $\|e_k\| \leqslant |||B^k||| \, \|e_0\| \to 0$ pour tout e_0 : $x_k \to x^*$. Avec la norme de Householder pour $\varepsilon = \frac{1-\rho}{2}$, on a même $\|e_k\| \leqslant q^k \|e_0\|$, $q = \frac{1+\rho}{2} < 1$: convergence géométrique.

Question 7

Soit $\lambda \in \mathbb{C}$ valeur propre avec $|\lambda| \geqslant 1$ et $v = a + ib \neq 0$ un vecteur propre associé ($a, b \in \mathbb{R}^n$). Alors $\|B^k v\| = |\lambda|^k \|v\| \geqslant \|v\| > 0$: $B^k v \not\to 0$. Comme B est réelle, $B^k v = B^k a + iB^k b$ avec $B^k a, B^k b$ réels ; si les deux tendaient vers 0, $B^k v$ aussi. Donc $B^k a \not\to 0$ ou $B^k b \not\to 0$: avec $x_0 = x^* + a$ ou $x_0 = x^* + b$ (réels), $e_k = B^k e_0 \not\to 0$.

Question 8

Le sup sur la sphère réelle vaut la norme subordonnée réelle $|||B^k|||_\infty$, qui est encore $\max_i \sum_j |(B^k)_{i,j}|$ (Q1, avec $x_j = \pm 1$). Par Q4, $|||B^k|||_\infty^{1/k} \to \rho(B)$. Heuristiquement $\|e_k\| \approx \rho(B)^k$: le nombre d'itérations pour gagner un facteur 10 est $\approx \frac{\ln 10}{-\ln \rho(B)}$. On appelle $-\ln \rho(B)$ la vitesse asymptotique.

Question 9

La matrice d'itération est $J = -D^{-1}(L+U)$, de coefficients $-\frac{a_{i,j}}{a_{i,i}}$ hors diagonale et 0 sur la diagonale. Par Q1,

$$\rho(J) \leqslant |||J|||_\infty = \max_i \frac{\sum_{j\neq i} |a_{i,j}|}{|a_{i,i}|} < 1,$$

d'où la convergence (Q6). Pour $A = \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix}$ (inversible, $\det A = 2$, dominance large), $J = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$ a pour valeurs propres $\pm i$: $\rho(J) = 1$ et Jacobi ne converge pas pour tout x_0 (Q7). Le livre énonce la condition avec $\geqslant$: il faut l'inégalité stricte.

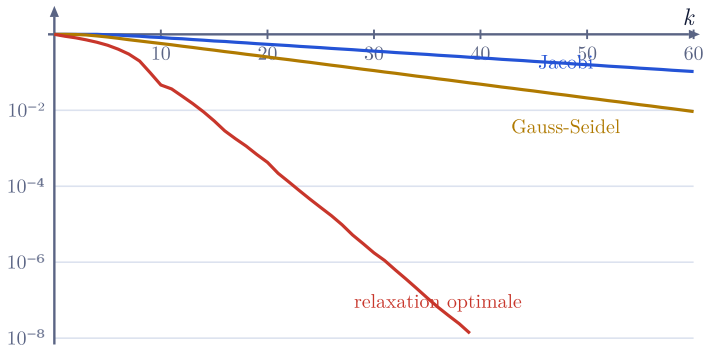
Question 10

Jacobi. $J = I - D^{-1}A = \frac{1}{2}\begin{pmatrix} 0 & 1 & 0 \\ 1 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}$, $\chi_J = \lambda^3 - \frac{1}{2}\lambda$, valeurs propres $0, \pm\frac{\sqrt{2}}{2}$: $\rho_J = \frac{\sqrt{2}}{2}$.

Gauss-Seidel. λ est valeur propre de $(D+L)^{-1}(-U)$ si et seulement si $\det\big(\lambda(D+L)+U\big) = 0$. On développe selon la première ligne :

$$\det\begin{pmatrix} 2\lambda & -1 & 0 \\ -\lambda & 2\lambda & -1 \\ 0 & -\lambda & 2\lambda \end{pmatrix} = 2\lambda(4\lambda^2 - \lambda) + (-2\lambda^2) = 8\lambda^3 - 4\lambda^2 = 4\lambda^2(2\lambda - 1).$$

Valeurs propres $0, 0, \frac{1}{2}$: $\rho_{GS} = \frac{1}{2} = \rho_J^2$. Gauss-Seidel va deux fois plus vite que Jacobi : $-\ln \rho_{GS} = -2\ln \rho_J$. C'est un cas du théorème $\rho_{GS} = \rho_J^2$ pour les matrices tridiagonales.



Erreur $\|x_k - x^*\|_\infty$ (échelle logarithmique) pour le laplacien discret $A = \mathrm{tridiag}(-1, 2, -1)$ de taille 10, $x_0 = 0$. Les pentes valent $\log_{10}\rho$: $\rho_J = \cos\frac{\pi}{11} \approx 0{,}959$, $\rho_{GS} = \rho_J^2 \approx 0{,}921$, et $\rho_{\omega_0} = \omega_0 - 1 \approx 0{,}560$ pour $\omega_0 \approx 1{,}560$.

Question 11

$M = \frac{1}{\omega}D + L$ est triangulaire inférieure de diagonale $\frac{1}{\omega}D$, et $N = (\frac{1}{\omega} - 1)D - U$ triangulaire supérieure de diagonale $(\frac{1}{\omega} - 1)D$. Donc

$$\det(M^{-1}N) = \frac{(\frac{1}{\omega} - 1)^n \det D}{\omega^{-n} \det D} = (1-\omega)^n.$$

Par le rappel, $\rho(M^{-1}N)^n \geqslant |\det(M^{-1}N)| = |1-\omega|^n$, donc $\rho \geqslant |1-\omega|$ (Kahan). Si $\omega \notin]0,2[$, $\rho \geqslant 1$ et la méthode ne converge pas pour tout x_0 (Q7).

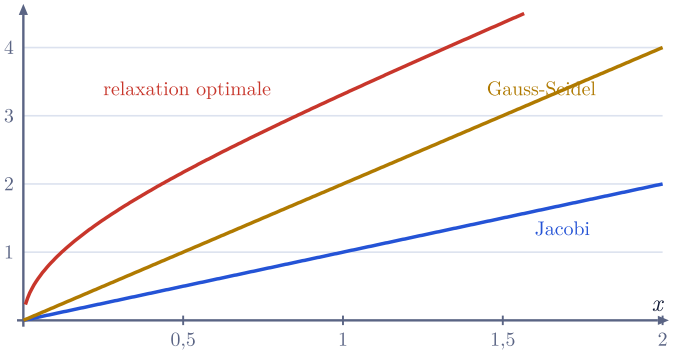
Question 12

$\omega_0 = \frac{2}{1+1/\sqrt{2}} = \frac{2\sqrt{2}}{\sqrt{2}+1} = 2\sqrt{2}(\sqrt{2}-1) = 4 - 2\sqrt{2} \approx 1{,}172$, et $\rho(L_{\omega_0}) = 3 - 2\sqrt{2} \approx 0{,}172$.

Nombre d'itérations pour un facteur 10^6 : $k \approx \frac{6\ln 10}{-\ln \rho}$, soit

méthode	ρ	k
Jacobi	0,707	≈ 40
Gauss-Seidel	0,5	≈ 20
relaxation ω_0	0,172	≈ 8

Pour le laplacien de taille n, $\rho_J = \cos\frac{\pi}{n+1}$ tend vers 1 et l'écart se creuse : la vitesse de Jacobi est $x \approx \frac{\pi^2}{2(n+1)^2}$, celle de la relaxation optimale $\approx 2\sqrt{2}\sqrt{x} \approx \frac{2\pi}{n+1}$.



Vitesses de convergence $v = -\ln\rho$ pour une matrice symétrique définie positive tridiagonale, en fonction de la vitesse x de Jacobi : $v_{GS} = 2x$ et $v_{\omega_0} = -\ln(\omega_0 - 1) \sim 2\sqrt{2}\sqrt{x}$ quand $x \to 0$. Le gain de la relaxation optimale est énorme quand Jacobi est lent (x petit, cas des grands systèmes).

Le piège

Partie I. ρ n'est pas une norme ($\rho\begin{pmatrix}0&1\\0&0\end{pmatrix}=0$), et $|||B|||$ peut être bien plus grand que $\rho(B)$ pour une norme fixée. La norme de Householder dépend de B et de ε.
Partie II. Q7 : un vecteur propre complexe n'est pas une condition initiale admissible ; il faut passer par sa partie réelle ou imaginaire.
Partie III. Q11 donne seulement une condition nécessaire : $\omega \in]0,2[$ ne garantit la convergence que sous hypothèse (par exemple A symétrique définie positive).

La méthode

Partie I. Pour contrôler B^k, trigonaliser puis « écraser » la partie strictement triangulaire par conjugaison avec $\mathrm{diag}(1,\delta,\dots,\delta^{n-1})$.
Partie II. Méthode itérative linéaire : l'erreur est itérée par la matrice d'itération $B = M^{-1}N$; tout se lit sur $\rho(B)$.
Partie III. Pour comparer des méthodes itératives, comparer les rayons spectraux des matrices d'itération ; un déterminant donne une minoration gratuite de ρ.

Rappels de cours utilisés

- **Trigonalisation.**

$$A = PTP^{-1},\ T \text{ triangulaire},\ T_{i,i}=\lambda_i \implies \rho(A)=\max_i |T_{i,i}|.$$

- **Norme subordonnée.**

$$|||B||| = \sup_{\|x\|\leqslant 1}\|Bx\|, \qquad |||BC|||\leqslant |||B|||\,|||C|||, \qquad |||B^k|||\leqslant |||B|||^k, \qquad \rho(B)\leqslant |||B|||.$$

- **Déterminant et valeurs propres.**

$$\det B=\prod_i \lambda_i \implies |\det B|\leqslant \rho(B)^n.$$