CORRIGÉ · PROBLÈME · COMMANDO X-ENS SPÉ

L'inégalité de Le Cam : la loi de Poisson approche la binomiale

Énoncé

Cadre. Pour deux lois μ, ν sur $\mathbb{N}$, la **distance en variation totale** est $d(\mu,\nu) = \sup_{A\subset\mathbb{N}} |\mu(A) - \nu(A)|$. On note $\mathcal{B}(p)$ la loi de Bernoulli, $\mathcal{B}(n,p)$ la loi binomiale, $\mathcal{P}(\lambda)$ la loi de Poisson ($\mathbb{P}(Y=k) = e^{-\lambda}\frac{\lambda^k}{k!}$). Un **couplage** de μ et ν est un couple (X,Y) de variables définies sur un même espace, avec $X \sim \mu$ et $Y \sim \nu$.

Partie I. Variation totale et couplage

1. Montrer que $d(\mu,\nu) = \frac{1}{2}\sum_{k\geqslant 0} |\mu(k) - \nu(k)|$ (considérer $A_+ = \{k : \mu(k) > \nu(k)\}$).
2. (**Inégalité de couplage**) Si (X,Y) est un couplage de μ et ν, montrer que $d(\mu,\nu) \leqslant \mathbb{P}(X \neq Y)$.
3. Si $(X_i, Y_i)_{1\leqslant i\leqslant n}$ sont des couples, montrer que $\mathbb{P}(\sum X_i \neq \sum Y_i) \leqslant \sum_i \mathbb{P}(X_i \neq Y_i)$.

Partie II. Coupler Bernoulli et Poisson

Soit $p \in [0,1]$ et $U \sim \mathcal{U}([0,1])$. On pose $Y = \mathbf{1}_{\{U > 1-p\}}$, et on définit X en découpant $[0,1]$ en intervalles consécutifs de longueurs $e^{-p}\frac{p^k}{k!}$ $(k = 0, 1, 2, \dots)$: $X = k$ si U tombe dans le k-ième. En particulier $X = 0$ si $U \leqslant e^{-p}$ et $X = 1$ si $e^{-p} < U \leqslant e^{-p}(1+p)$.

1. Montrer que $Y \sim \mathcal{B}(p)$ et $X \sim \mathcal{P}(p)$.
2. Montrer que $\{X \neq Y\} = \{1 - p < U \leqslant e^{-p}\} \cup \{U > e^{-p}(1+p)\}$, et calculer $\mathbb{P}(X \neq Y) = p(1 - e^{-p})$.
3. En déduire $d(\mathcal{B}(p), \mathcal{P}(p)) \leqslant p^2$. Comparer avec la valeur exacte $d(\mathcal{B}(p), \mathcal{P}(p)) = p(1-e^{-p})$.

Partie III. L'inégalité de Le Cam

Soient $p_1, \dots, p_n \in [0,1]$, $S_n = \sum Y_i$ avec $Y_i \sim \mathcal{B}(p_i)$ indépendantes, et $\lambda = \sum p_i$.

1. En couplant chaque Y_i avec $X_i \sim \mathcal{P}(p_i)$ comme en Partie II (avec des uniformes indépendantes), montrer l'**inégalité de Le Cam** :

$$\sum_{k\geqslant 0} \left| \mathbb{P}(S_n = k) - e^{-\lambda}\frac{\lambda^k}{k!} \right| \leqslant 2\sum_{i=1}^{n} p_i^2.$$

2. En déduire $\sum_k |\mathcal{B}(n, \frac{\lambda}{n})(k) - \mathcal{P}(\lambda)(k)| \leqslant \frac{2\lambda^2}{n}$, et que $\mathcal{B}(n, \frac{\lambda}{n})$ converge vers $\mathcal{P}(\lambda)$.

3. Application : un livre de 500 pages contient 1000 coquilles réparties indépendamment et uniformément. Estimer la probabilité qu'une page donnée n'ait aucune coquille, et majorer l'erreur commise en utilisant la loi de Poisson.

Décoder l'énoncé

Ce que l'énoncé te donne.

- $\mu(A) = \sum_{k\in A} \mu(k)$.
- $1 - p \leqslant e^{-p} \leqslant e^{-p}(1+p)$.
- Parties I et II.

Ce qu'on te demande. On mesure l'écart entre deux lois sur $\mathbb{N}$ par la distance en variation totale, qu'on majore par la probabilité de désaccord d'un couplage. En couplant une variable de Bernoulli et une variable de Poisson de même paramètre par une même variable uniforme, on obtient Σ |P(S$_n$ = k) − e^{−λ}λ /k!| ⩽ 2 Σ p ^{2}, d'où l'erreur 2λ^2/n pour la binomiale B(n, λ/n).

Corrigé

Question 1

Pour $A \subset \mathbb{N}$, en ne gardant que les termes positifs : $\mu(A) - \nu(A) \leqslant \sum_{k\in A\cap A_+}(\mu(k)-\nu(k)) \leqslant \mu(A_+) - \nu(A_+)$. De même $\nu(A) - \mu(A) \leqslant \nu(A_+^c) - \mu(A_+^c)$. Or $\mu(A_+) - \nu(A_+) = \nu(A_+^c) - \mu(A_+^c)$ (les deux lois sont de masse 1), et leur somme est $\sum_k |\mu(k) - \nu(k)|$. Donc le sup est atteint en A_+ et

$$d(\mu,\nu) = \mu(A_+) - \nu(A_+) = \frac{1}{2}\sum_k |\mu(k) - \nu(k)|.$$

Question 2

$\{X \in A\} \subset \{Y \in A\} \cup \{X \neq Y\}$, donc $\mu(A) = \mathbb{P}(X \in A) \leqslant \nu(A) + \mathbb{P}(X \neq Y)$. Symétriquement, d'où $|\mu(A) - \nu(A)| \leqslant \mathbb{P}(X \neq Y)$ pour tout A, et $d(\mu,\nu) \leqslant \mathbb{P}(X \neq Y)$.

Question 3

$\{\sum X_i \neq \sum Y_i\} \subset \bigcup_i \{X_i \neq Y_i\}$, et la probabilité d'une réunion est majorée par la somme des probabilités.

Question 4

$\mathbb{P}(Y = 1) = \mathbb{P}(U > 1-p) = p$: $Y \sim \mathcal{B}(p)$. Pour X, on découpe $[0,1]$ en intervalles consécutifs de longueurs $e^{-p}\frac{p^k}{k!}$ $(k = 0, 1, 2, \dots)$, de somme 1 ; $X = k$ sur le k-ième. Les deux premiers sont $]0, e^{-p}]$ et $]e^{-p}, e^{-p}(1+p)]$. Donc $X \sim \mathcal{P}(p)$.

Question 5

Par le rappel, $1-p \leqslant e^{-p}$. On distingue :

- $U \leqslant 1-p$: $Y=0$ et $U \leqslant e^{-p}$ donc $X=0$;
- $1-p < U \leqslant e^{-p}$: $Y=1$, $X=0$: **désaccord** ;
- $e^{-p} < U \leqslant e^{-p}(1+p)$: $Y=1$, $X=1$;
- $U > e^{-p}(1+p)$: $Y=1$, $X \geqslant 2$: **désaccord**.

$$\mathbb{P}(X \neq Y) = (e^{-p} - (1-p)) + (1 - e^{-p}(1+p)) = p - pe^{-p} = p(1-e^{-p}).$$

Question 6

Par Q2 et $1-e^{-p} \leqslant p$: $d(\mathcal{B}(p), \mathcal{P}(p)) \leqslant p(1-e^{-p}) \leqslant p^2$.

Valeur exacte : $\mathcal{B}(p)$ charge 0 et 1 ; par Q1, $d = \frac{1}{2}(|1-p-e^{-p}| + |p-pe^{-p}| + \sum_{k\geqslant 2} e^{-p}\frac{p^k}{k!}) = \frac{1}{2}((e^{-p}-1+p) + p(1-e^{-p}) + (1-e^{-p}-pe^{-p})) = p(1-e^{-p})$. Le couplage est donc **optimal**.

Question 7

Avec des uniformes $U_1, \dots, U_n$ indépendantes, les couples (X_i, Y_i) sont indépendants ; $Y_i \sim \mathcal{B}(p_i)$, $X_i \sim \mathcal{P}(p_i)$, et $T = \sum X_i \sim \mathcal{P}(\lambda)$ (rappel). Par Q2, Q3 et Q6 :

$$d(\mathcal{L}(S_n), \mathcal{P}(\lambda)) \leqslant \mathbb{P}(S_n \neq T) \leqslant \sum_i \mathbb{P}(X_i \neq Y_i) \leqslant \sum_i p_i^2.$$

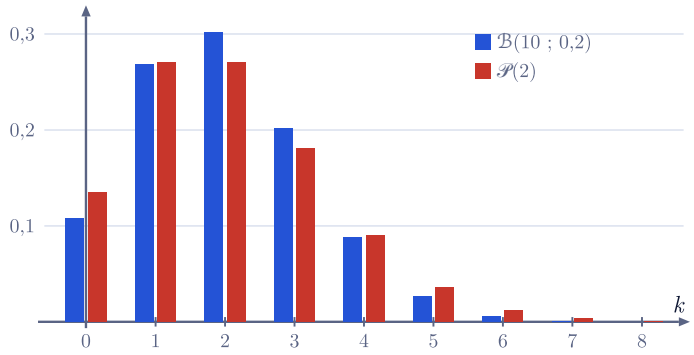
Par Q1, $\sum_k |\mathbb{P}(S_n=k) - \mathbb{P}(T=k)| = 2d \leqslant 2\sum p_i^2$.

Question 8

Avec $p_i = \frac{\lambda}{n}$, $S_n \sim \mathcal{B}(n, \frac{\lambda}{n})$ et $2\sum p_i^2 = \frac{2\lambda^2}{n}$:

$$\sum_k \left| \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} - e^{-\lambda}\frac{\lambda^k}{k!} \right| \leqslant \frac{2\lambda^2}{n}.$$

En particulier, pour chaque k, $\mathcal{B}(n, \frac{\lambda}{n})(k) \to \mathcal{P}(\lambda)(k)$, avec une vitesse explicite en $\frac{1}{n}$, uniforme en k.



$\mathcal{B}(10\,;0{,}2)$ (bleu) et $\mathcal{P}(2)$ (rouge) : même moyenne, lois proches. La somme des écarts vaut environ 0,10, sous la borne de Le Cam $\frac{2\lambda^2}{n} = 0{,}8$ (qui est loin d'être optimale pour n petit, mais tend vers 0).

Question 9

Chaque coquille tombe sur la page donnée avec probabilité $\frac{1}{500}$, indépendamment : le nombre N de coquilles de la page suit $\mathcal{B}(1000, \frac{1}{500})$, de moyenne $\lambda = 2$. Approximation de Poisson : $\mathbb{P}(N=0) \approx e^{-2} \approx 0{,}135$. Erreur : $|\mathbb{P}(N=0) - e^{-2}| \leqslant d \leqslant \sum p_i^2 = 1000 \cdot \frac{1}{500^2} = 0{,}004$.

(Valeur exacte : $(1-\frac{1}{500})^{1000} \approx 0{,}1351$, et $e^{-2} \approx 0{,}1353$: l'erreur réelle est de l'ordre de $3 \cdot 10^{-4}$.)

Le piège

Partie I. La distance en variation totale ne dépend que des lois, pas du couplage : l'inégalité de couplage est vraie pour **tout** couplage, et l'art consiste à en choisir un où X et Y coïncident le plus souvent possible.
Partie II. Coupler deux variables indépendantes de lois $\mathcal{B}(p)$ et $\mathcal{P}(p)$ donne $\mathbb{P}(X \neq Y) \approx 2p$, bien trop grand : l'intérêt du couplage par une même uniforme est de faire coïncider les deux variables autant que possible.
Partie III. L'inégalité ne demande pas que les p_i soient égaux : c'est la « loi des petits nombres » pour des événements rares de probabilités différentes. Ce qui compte est que $\sum p_i^2$ soit petit devant 1, même si $\lambda = \sum p_i$ est de taille quelconque.

La méthode

Partie I. Méthode de couplage : pour comparer deux lois, construire sur un même espace deux variables de ces lois, égales avec grande probabilité.
Partie II. Couplage par la fonction quantile : utiliser la même uniforme U pour simuler les deux lois ; elles diffèrent seulement là où leurs fonctions de répartition diffèrent.
Partie III. Approximation poissonienne : coupler chaque Bernoulli avec une Poisson de même paramètre, sommer, et contrôler l'erreur par $\sum p_i^2$.

Rappels de cours utilisés

- **Simulation par une uniforme.**

$$U \sim \mathcal{U}([0,1]), \quad c_{k+1} - c_k = q_k, \quad X = k \text{ sur } \{c_k < U \leqslant c_{k+1}\} \implies P(X=k) = q_k.$$

- **Deux inégalités.** Pour $p \geqslant 0$: $1-p \leqslant e^{-p}$, et $e^{-p} \geqslant 1-p$ donne $1-e^{-p} \leqslant p$.
- **Somme de Poisson indépendantes.** Si $X \sim \mathcal{P}(\lambda)$ et $Y \sim \mathcal{P}(\mu)$ sont indépendantes, $X+Y \sim \mathcal{P}(\lambda+\mu)$: $\mathbb{P}(X+Y=k) = \sum_j e^{-\lambda}\frac{\lambda^j}{j!} e^{-\mu}\frac{\mu^{k-j}}{(k-j)!} = e^{-(\lambda+\mu)}\frac{(\lambda+\mu)^k}{k!}$ (binôme).