CORRIGÉ · ORAL CCINP · ORAUX DE MATHS SPÉ

Combien de tirages pour estimer une proportio

Énoncé

1. Rappeler l'inégalité de Bienaymé-Tchebychev.
2. Soit (Y_n) une suite de variables indépendantes de même loi, de variance finie, et $S_n = \sum_{k=1}^{n} Y_k$. Montrer que pour tout $a > 0$: $P\left(\left|\frac{S_n}{n} - E(Y_1)\right| \geqslant a\right) \leqslant \frac{V(Y_1)}{na^2}$.
3. On tire avec remise dans une urne de 1 boule rouge et 3 noires. À partir de combien de tirages peut-on garantir, avec probabilité au moins 90 %, que la proportion de rouges est strictement entre 0,2 et 0,3 ?

Décoder l'énoncé

Ce que l'énoncé te donne.

- $p = \frac{1}{4}$, $V = \frac{1}{4} \cdot \frac{3}{4} = \frac{3}{16}$.

Ce qu'on te demande. Loi faible des grands nombres quantitative.

Corrigé

L'inégalité

Inégalité de Bienaymé-Tchebychev : si X admet une variance, pour tout $a > 0$,

$$P(|X - E(X)| \geqslant a) \leqslant \frac{V(X)}{a^2}.$$

Lecture : la probabilité de s'écarter de la moyenne d'au moins a est contrôlée par la variance. Exemple : si $V(X) = 1$, la probabilité de s'écarter d'au moins 3 est $\leqslant \frac{1}{9}$.

Moyenne empirique

On note $m = E(Y_1)$, $\sigma^2 = V(Y_1)$. Par linéarité : $E(S_n) = nm$, donc $E(\frac{S_n}{n}) = m$.

Par indépendance, les variances s'ajoutent : $V(S_n) = n\sigma^2$. Et $V(cX) = c^2V(X)$, donc

$$V\left(\frac{S_n}{n}\right) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}.$$

On applique Q1 à $X = \frac{S_n}{n}$:

$$P\Big(\Big|\frac{S_n}{n} - E(Y_1)\Big| \geqslant a\Big) \leqslant \frac{V(Y_1)}{na^2}.$$

Modéliser

On pose $Y_i = 1$ si le i-ième tirage est rouge, 0 sinon. Les tirages sont avec remise : les Y_i sont indépendantes, de loi de Bernoulli de paramètre $\frac{1}{4}$ (1 rouge sur 4 boules). Donc

$$E(Y_1) = \frac{1}{4}, \qquad V(Y_1) = \frac{1}{4} \times \frac{3}{4} = \frac{3}{16}.$$

$\frac{S_n}{n}$ est la proportion de rouges. « Strictement entre 0,2 et 0,3 » signifie $\left|\frac{S_n}{n} - 0{,}25\right| < 0{,}05$.

Trouver n

On veut $P(\left|\frac{S_n}{n} - \frac{1}{4}\right| < 0{,}05) \geqslant 0{,}9$, c'est-à-dire, avec l'événement contraire, $P(\left|\frac{S_n}{n} - \frac{1}{4}\right| \geqslant 0{,}05) \leqslant 0{,}1$. Par Q2 avec $a = 0{,}05$, $a^2 = 0{,}0025$:

$$P\Big(\Big|\frac{S_n}{n} - \frac{1}{4}\Big| \geqslant 0{,}05\Big) \leqslant \frac{3/16}{0{,}0025\,n} = \frac{0{,}1875}{0{,}0025\,n} = \frac{75}{n}.$$

Il suffit donc que $\frac{75}{n} \leqslant 0{,}1$, c'est-à-dire $n \geqslant 750$.

$$n \geqslant 750.$$

C'est une condition suffisante : la borne de Bienaymé-Tchebychev est grossière, et en réalité beaucoup moins de tirages suffisent.

Le piège

Oublier de passer à l'événement contraire : l'inégalité majore la probabilité de **s'écarter**.

La méthode

Taille d'échantillon : $\frac{V}{na^2} \leqslant \alpha$.

Rappels de cours utilisés

- **Inégalité de Bienaymé-Tchebychev.**

$$\forall a > 0, \quad P(|X - E(X)| \geqslant a) \leqslant \frac{V(X)}{a^2}.$$

$$X_i \text{ i.i.d.} \implies V\Big(\frac{S_n}{n}\Big) = \frac{V(X_1)}{n}, \qquad P\Big(\Big|\frac{S_n}{n} - m\Big| \geqslant a\Big) \leqslant \frac{V(X_1)}{na^2}.$$

- **Indépendance de deux variables.**

$$X, Y \text{ indépendantes } \iff \forall x, y,\ P(X = x, Y = y) = P(X = x)P(Y = y).$$

Si elles le sont : $E(XY) = E(X)E(Y)$, $V(X+Y) = V(X)+V(Y)$, $E(f(X)g(Y)) = E(f(X))E(g(Y))$.