PROBLÈME · COMMANDO X-ENS SPÉ · 1 H 30

Compter jusqu'à n avec log log n bits

Cadre. On veut compter des événements (des requêtes reçues par un serveur, par exemple) sans stocker le nombre exact n, qui demande $\lfloor \log_2 n \rfloor + 1$ bits. Soit $(u_{i,j})_{i \geqslant 0,\, j \geqslant 1}$ une famille de variables aléatoires **indépendantes**, avec $u_{i,j}$ de loi de Bernoulli de paramètre 2^{-i}. On pose $S_0 = 0$ et, pour $n \geqslant 0$,

$$S_{n+1} = S_n + u_{S_n,\, n+1}.$$

Autrement dit, à la $(n+1)$-ième requête, le compteur passe de S_n à $S_n + 1$ avec probabilité 2^{-S_n}. On pose $Y_n = 2^{S_n} - 1$. Pour $\varepsilon, \delta \in]0,1[$, un (ε, δ)**-estimateur** de $\mu > 0$ est une variable Z telle que $\mathbb{P}(|Z - \mu| \geqslant \varepsilon \mu) \leqslant \delta$.

Partie I. Un estimateur sans biais de n

1. Montrer que $0 \leqslant S_n \leqslant n$, que $S_1 = 1$, et que S_n est une fonction des seules variables $(u_{i,j})_{i \geqslant 0,\, j \leqslant n}$. En déduire que, pour tout k, S_n et $u_{k,n+1}$ sont indépendantes.

2. Calculer $\mathbb{E}\big[2^{u_{k,n+1}}\big]$, puis montrer que $\mathbb{E}\big[2^{S_{n+1}}\big] = \mathbb{E}\big[2^{S_n}\big] + 1$ (on pourra écrire $2^{S_{n+1}} = \sum_{k=0}^{n} 2^{k + u_{k,n+1}} \mathbf{1}_{S_n = k}$).

3. Retrouver ce résultat par une autre méthode : calculer $\mathbb{P}(S_{n+1} = k,\ S_n = k)$ et $\mathbb{P}(S_{n+1} = k,\ S_n = k-1)$, puis $\mathbb{E}\big[2^{S_{n+1}} - 1\big]$ par la formule de transfert.

4. En déduire $\mathbb{E}[Y_n] = n$. Calculer la loi de S_2 et vérifier.

Partie II. Variance et (,)-estimateur

1. Montrer que $\mathbb{E}\big[4^{S_{n+1}}\big] = \mathbb{E}\big[4^{S_n}\big] + 3(n+1)$, puis que $\mathbb{E}\big[4^{S_n}\big] = 1 + \frac{3n(n+1)}{2}$.

2. En déduire $\mathrm{Var}(Y_n) = \dfrac{n(n-1)}{2}$. Vérifier pour $n = 1$ et $n = 2$.

3. Montrer que Y_n seul n'est pas un bon estimateur : majorer $\mathbb{P}(|Y_n - n| \geqslant \varepsilon n)$ par Bienaymé-Tchebychev et commenter.

4. Soient $S_n^{(1)}, \dots, S_n^{(k)}$ des copies indépendantes de S_n (construites avec des familles u indépendantes), $Y_n^{(i)} = 2^{S_n^{(i)}} - 1$ et $U_n = \frac{1}{k} \sum_{i=1}^{k} Y_n^{(i)}$. Montrer que U_n est un (ε, δ)-estimateur de n dès que $k \geqslant \dfrac{1}{2\varepsilon^2 \delta}$.

Partie III. La mémoire utilisée, presque sûrement

On garde les notations de la Partie II, k étant fixé.

1. (**Borel-Cantelli**) Soit (A_n) une suite d'événements telle que $\sum \mathbb{P}(A_n) < +\infty$. Montrer que $\mathbb{P}(\limsup A_n) = 0$.

2. Pour stocker U_n, on stocke les k entiers $S_n^{(i)} \geqslant 1$ ($n \geqslant 1$), ce qui demande $B_n = \sum_{i=1}^{k} (\lfloor \log_2 S_n^{(i)} \rfloor + 1)$ bits. On note $L_n = \log_2 \log_2 n$. Montrer que, pour $n \geqslant 4$,

$$\{B_n \geqslant 3kL_n\} \subset \bigcup_{i=1}^{k} \left\{ Y_n^{(i)} - n \geqslant n^{\log_2 n} - n - 1 \right\}.$$

3. En déduire que $\mathbb{P}(B_n \geqslant 3kL_n) \leqslant \dfrac{2k}{n^6}$ pour $n \geqslant 16$.

4. Conclure que, presque sûrement, $B_n < 3k \log_2 \log_2 n$ pour tout n assez grand. Comparer avec le stockage exact de n.