PROBLÈME · ANNALES MP · 35 MIN

Analyse d'un texte, dictionnaires et SQL

Consignes Python : pas de fonctions internes sur les listes ou chaînes (`min`, `max`, `count`, `remove`…) ; seules `len`, `append`, le tranchage et la concaténation sont permis. Programmes commentés si nécessaire.

Alice compresse un message, l'encode, le transmet ; Bob le décode puis le décompresse. On étudie la compression (codage arithmétique) puis le décodage (algorithme de Viterbi).

Avec le code de longueur fixe `'a'` = 00, `'b'` = 01, `'c'` = 10, la chaîne `s='abaabaca'` tient sur 16 bits. On peut coder `'a'` sur 1 bit et `'b'`, `'c'` sur 2 bits pour obtenir 11 bits.

1. Proposer une telle représentation décodable sans ambiguïté, avec code(`'a'`) < code(`'b'`) < code(`'c'`).

2. Écrire `nbCaracteres(c:str, s:str) -> int` (nombre d'occurrences de `c` dans `s`), linéaire en $n =$ `len(s)`.

3. Que renvoie `listeCaracteres('abaabaca')` ? Expliquer son principe.

```
def listeCaracteres(s:str):
    listeCar = []
    n = len(s)
    for i in range(n):
        c = s[i]
        if not(c in listeCar):
            listeCar.append(c)
    return listeCar
```

4. Complexité dans le pire cas en fonction de n et du nombre k de caractères distincts (le test `c in listeCar` est linéaire en la longueur de `listeCar`).

5. Que fait `analyseTexte` ? Valeur de `analyseTexte('babaaaabca')` ?

```
def analyseTexte(s:str):
    R = []
    l = listeCaracteres(s)
    for i in range(len(l)):
        c = l[i]
        R.append((c, nbCaracteres(c, s)))
    return R
```

6. Complexité de `analyseTexte` en fonction de n et k.

7. Réécrire `analyseTexte` avec un dictionnaire, en complexité linéaire en n, indépendante de k, avec un seul parcours de la chaîne. Exemple : `analyseTexte('abracadabra')` renvoie

`{'a':5, 'b':2, 'r':2, 'c':1, 'd':1}`.

Base de données : `caractere(idCar, symbole, typeCaractere, codeHTML)` ; `corpus(idLivre, titre, auteur, annee, nombreCaracteres, langue)` ; `occurrences(idCar, idLivre, nombreOccurrences)`

1. Requête SQL : liste sans doublon des auteurs de `corpus`.
2. Requête SQL : pour chaque caractère, le symbole et sa fréquence en `'Français'` (nombre total d'occurrences divisé par le nombre total de caractères des textes du corpus).