PROBLÈME · ANNALES SPÉ · 30 MIN

Estimer le cardinal d'un flot : HyperLogLog

Cardinal d'un flot = nombre de valeurs distinctes. Le premier bit activé $\varrho(h)$ d'un entier $h \in [\![0, 2^{62}-1]\!]$ est le plus grand i tel que les $i-1$ bits de droite sont nuls ; $\varrho(0) = 63$ (exemples : $\varrho(1) = 1$, $\varrho(6) = 2$, $\varrho(8) = 4$). Hachage par `String.hash`.

1. Écrire `ffs (h:int) : int`.

Deux algorithmes sur les t premiers termes : `cardinality_nf` remplit une table de hachage et renvoie son nombre d'éléments ; `cardinality_fm` garde $r = \max \varrho(H(u))$ et renvoie 2^r.

1. Comparer leurs complexités en espace.
2. Écrire `harmonic_mean (z:float array) : float` ($\text{Harm} = m(\sum \frac{1}{z_j})^{-1}$).

HyperLogLog ($m = 16$, $\alpha_{16} = 0{,}6731$) : le terme u va dans le sous-flot $i = H(u) \bmod m$, et $r_i = \max \varrho(H(u)/m)$ sur ce sous-flot ; estimation $s \simeq \alpha_m \cdot m \cdot \text{Harm}(2^{r_0}, \dots, 2^{r_{m-1}})$.

1. Écrire `hll_update (r:int array) (x:string) : unit` (met à jour r avec le nouveau terme x).
2. Écrire `mean_estimate (r:int array) : float`.
3. Dans le code multi-fils donné (deux fils remplissent `r_u` et `r_v` par `hll_update` ; le fil principal calcule toutes les 5 secondes `Array.init m (fun i -> max r_u.(i) r_v.(i))` et affiche l'estimation), identifier les courses critiques et proposer un mécanisme de correction.